

실전 이탈 예측 모델링을 위한 세 가지 고려 사항

0. 시작하며

최근 몇 년간 이탈 예측 모델링 관련 업무를 하고 있습니다. 공식적으로 프로젝트를 진행하거나 팀 내부적으로 조사 및 연구를 진행한 적도 있고, 경진 대회를 통해 다양한 참가자들의 결과물을 심사하기도 했죠. 하지만 아쉽게도 여전히 이탈 예측 모델 결과를 실제 서비스에 적용하지는 못하고 있습니다.

이렇게 다양한 방법을 시도하고 실패하면서 몇 가지 큰 교훈과 깨달음을 얻었는데, 크게 아래와 같이 세 가지로 정리할 수 있겠습니다.

예측 모델의 목표는 오차를 최소화하는 것이 아니다 (기대 이익을 최대화하는 것이다).

Concept drift는 모델링 전반에 걸쳐 고려해야 할 문제이다 (모델의 유지 보수에서만 문제가 아니다).

예측 모델링과 인과 추론 모델링은 다르다 (모델을 통해 알고자 하는 바에 따라 다른 접근 방법이 필요하다).

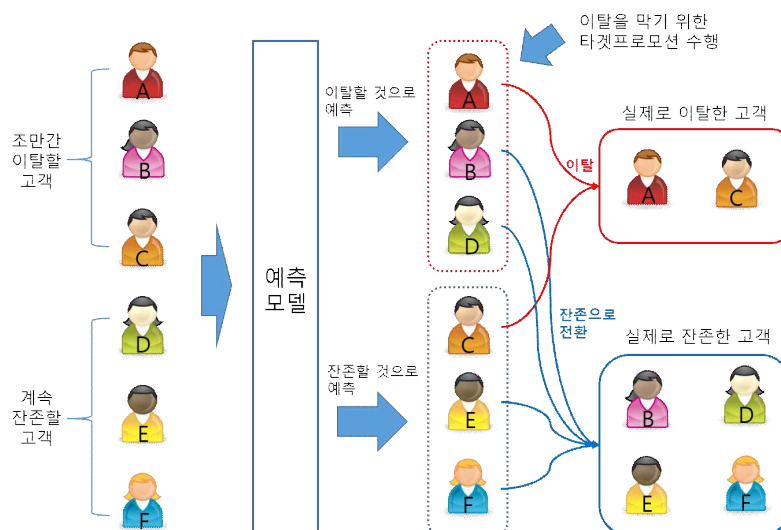
비록 ‘이탈 예측’이라는 분야로 한정하긴 했지만 아마 기계 학습을 실전에 활용하려는 다른 많은 분야에서도 고려해 볼만한 요소이지 않을까 생각합니다. 이 글에서는 이 세 가지 깨달음을 정리해 보겠습니다.

1. 예측 모델의 목표는 오차를 최소화하는 것이 아니다.

현재 대부분의 경우 기계 학습 모델을 만들 때 라벨 정보와 예측 결과 사이의 오차를 최소화하는 것을 목표로 학습합니다. 그래서 모델의 성능을 측정할 때 RMSE 나 accuracy 혹은 F1 score 같은 예측치와 실측치 사이의 오차를 측정하는 방법을 사용합니다.

그러나 실제 서비스에서 예측 모델을 사용하는 본질적인 목적은 정답을 잘 맞추겠다가 아니라 예측 모델을 실전에 적용함으로써 이익을 얻겠다 입니다. 따라서 실제 예측 모델이 목표로 해야할 것은 오차를 최소화하는 것이 아니라 모델 적용을 통해 기대되는 이익을 최대화하는 것이죠 (참고로 이익이 꼭 돈을 의미하는 것은 아닙니다). 물론 오차를 최소화하는 것이 곧 기대 이익을 최대화하는 것과 동일한 경우도 많습니다. 그러나 이 두 가지 목표를 동일시해서는 안됩니다. 적어도 ‘이탈 예측’에서는 그렇습니다.

좀 더 구체적인 설명을 위해 [그림 1]과 같은 시나리오를 한번 생각해 보죠.



A 부터 F 까지 여섯 명의 고객이 있습니다. A, B, C 는 각자 어떤 이유로 인해 조만간 더 이상 우리 서비스를

이용하지 않고 이탈하려는 고객입니다. 그리고 D, E, F 는 서비스에 만족하고 있어서 계속 이용하려는 고객이고요. 예측 모델은 이런 고객들의 여러 가지 특성들을 분석해서 조만간 이탈할 것으로 추정되는 고객과 그렇지 않은 고객을 분류합니다. 그런데 이 예측이 100% 정확하기는 현실적으로 거의 불가능하기 때문에 약간의 오차 (사실은 상당한 오차) 가 발생할 수 있습니다. 가령 위 예측 모델은 A, B, D 가 이탈할 것이라고 예측했는데, 이런 경우 A 와 B 는 실제 이탈할 생각이 있었으니 정확히 예측했지만 D 는 잘못 예측했죠. 이것을 각각 'true positive (TP)' 와 'false positive (FP)' 라고 부릅니다. 한편, E 와 F 는 이탈할 생각이 없는 고객이며 예측 모델 역시 이탈할 고객이 아니라는 것을 정확히 예측했습니다. 하지만 C 의 경우 이탈할 생각을 하고 있지만 예측 모델이 이것을 제대로 탐지하지 못했죠. 이 경우에는 E 와 F 를 'true negative (TN)' 라고 부르며 C 를 'false negative (FN)' 라고 부릅니다. 우리말로는 보통 TP 와 TN 을 '정탐 (정확히 탐지함)' 이라고 부르며, FP 는 '오탐 (잘못 탐지함)', FN 은 '미탐 (탐지하지 못함)' 이라고 부릅니다.

A 와 B - true positive, TP

C - false negative, FN

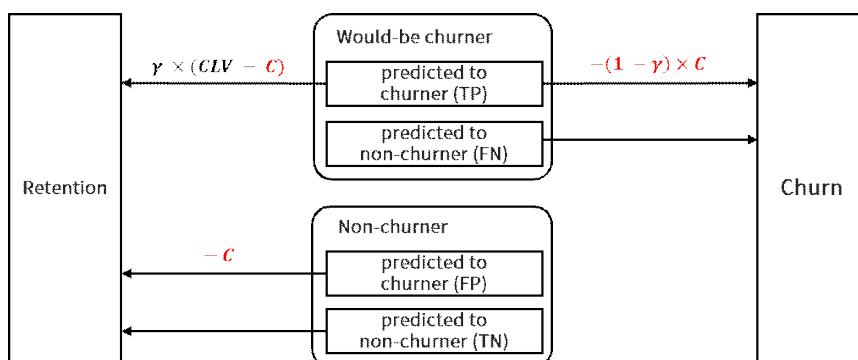
D - false positive, FP

E 와 F - true negative, TN

이제 마케팅 부서에서는 예측 모델 결과를 토대로 A, B, D 고객에게는 마음을 돌리기 위한 어떤 보상 조건을 제시하거나 혹은 타겟팅된 광고를 노출할 수 있습니다. 그런데 이런 광고나 프로모션이 항상 성공하는 것은 아닙니다. 어떤 고객은 이런 프로모션에 반응해 좀 더 서비스를 이용해 보기로 생각할 수 있겠지만 어떤 고객은 원래 생각대로 이탈할 것입니다. 위 시나리오에서 B 는 마음을 바꿔 잔존했고, A 는 프로모션에 반응하지 않고 그대로 이탈했습니다. 이렇게 어떤 프로모션에 반응하는 비율을 '전환율 (conversion rate)' 이라고 부릅니다. 한편, C 는 예측 모델이 이탈할 것을 예측하지 못했기 때문에 방치되었고 그래서 그대로 이탈해 버립니다. 반면 D 고객은 원래 이탈할 생각도 없었는데 예측 모델이 이탈할 것이라고 잘못 예측한 덕분에 프로모션을 통해 어떤 보상을 거쳐 받을 수 있습니다. 그런데 프로모션이나 광고에는 비용이 발생합니다. 이 비용에는 고정 비용도 있겠지만 대상 규모가 커짐에 따라 커지는 단가 개념이 적용되는 비용도 있습니다. 따라서 D 와 같은 고객이 많아지면 이탈 방지를 통한 기대 이익이 줄어든 것입니다.

더 나아가 각 고객이 발생시키는 기대 가치는 저마다 다릅니다. 가령, C 고객이 매우 큰 매출을 발생시키는 VIP 고객이었다면, 이탈을 탐지하지 못해 발생하는 손실은 C 고객이 평균적인 매출을 발생시키는 고객일때에 비해 훨씬 클 것입니다.

이제 위 시나리오를 토대로 이탈 방지를 위한 프로모션을 도입했을 때 예상되는 비용과 이익을 도식화하여 표현하면 [그림 2]와 같습니다. 아래 도식에서 ' γ (감마)'는 전환율을 의미하며, CLV는 고객에 대한 기대 가치, C는 프로모션 비용을 의미합니다. 이탈할 것이라고 예측한 TP 와 FP 에는 프로모션 비용이 발생합니다. FP (위 시나리오에서 D 고객) 는 원래 프로모션과 상관없이 잔존하는 고객이기 때문에 추가적인 이득은 없이 비용만 낭비됩니다. 한편 FN (C 고객) 이나 TN (E 와 F 고객) 은 그대로 방치된 고객이므로 비용과 이익 모두 발생하지 않습니다. TP (A 와 B 고객) 는 원래 이탈하려는 고객이었기 때문에 프로모션을 통해 잔존으로 전환되는 비율 (γ) 만큼의 이익이 발생하는데, 이 때의 이익은 원래의 고객 가치 (CLV) 에서 프로모션 비용 (C) 을 제한 만큼이 됩니다.



결국 이탈 예측 모델을 실전에 적용하여 잔존율을 높이기 위한 프로모션을 수행하게 되면 모델의 예측 정확도 뿐만 아니라 기대 가치와 프로모션 비용, 전환율 등을 모두 고려해야 본질적으로 추구하는 기대 이익을 계산할 수 있습니다. 이를 수식화하면 다음과 같으며, 이탈 예측 모델의 최종 목표는 이 값을 최대화하는 것이 되어야 합니다.

$$Profit = CLV(\gamma \times TP) - C(TP + FP)$$

이 값(Profit)을 크게 하려면 TP 를 높이거나 FP 를 줄이는 것도 중요하지만 비용을 줄이거나 전환율을 높이거나 혹은 기대 가치가 큰 고객의 이탈 징후를 잘 탐지하는 것도 중요합니다. 예측 모델을 만드는 데이터 분석가의 입장에서 전환율이나 마케팅 비용을 제어하기는 불가능하지만, 대신 기대 가치가 큰 고객의 이탈 징후를 잘 탐지하는 것을 목표로 예측 모델을 만들 수 있습니다.

저희 팀에서 작년에 IEEE Transactions on Games에 발표한 논문에서는 기대 이익을 고려하여 예측 대상을 선정하고 모델 성능을 평가하는 방법을 제안하고 있습니다. 이탈 예측 모델을 만들고 이를 적용할 때 전체 고객을 모두 예측 대상으로 활용하는 것이 아니라 소수이지만 기대 이익이 큰 고객으로 대상을 한정하는 것이죠. 이렇게 하면 이탈 징후를 찾기 힘든 소수의 데이터만 사용하게 되어 예측 정확도 측면에서는 손해를 봅니다. 그러나 프로모션 비용을 고려하면, 프로모션 단가보다 낮은 기대 가치를 갖는 고객의 이탈을 예측하는 것은 원래의 목표에 맞지 않습니다. 즉, 프로모션 비용 대비 기대 가치가 큰 고객에 집중하면 정확도는 떨어지더라도 기대 이익은 높은 모델을 만들 수 있을 것입니다.

[그림 3]은 위에서 정의한 평가식을 이용해 이런 가설을 실험으로 검증한 자료입니다. 표에서 ‘Test set I’ 이 전체 고객을 대상으로 샘플링한 자료로 이탈 예측 모델을 만들어 테스트한 결과이고 ‘Test set II’ 은 CLV가 높은 고객을 선별하여 모델을 만들어 테스트한 결과입니다. 예측 성능을 측정한 ‘accuracy’, ‘precision’, ‘recall’, ‘F1 score’, ‘AUC’ 항목을 보면 ‘Test set I’ 이 ‘Test set II’ 에 비해 모든 면에서 훨씬 높은 값을 기록했습니다. 그러나 전환율이나 프로모션 비용을 고려하여 기대 이익을 측정할 경우 ‘Test set I’ 은 프로모션 비용이 없거나 매우 낮게 책정했을 경우를 제외하면 기대 이익은 커녕 오히려 손해를 보는 것으로 나옵니다. 반면 ‘Test set II’ 는 대부분의 시나리오에서 높은 기대 이익이 예상됩니다.

TABLE IX
COMPARISON OF PREDICTION PERFORMANCE AND EXPECTED PROFIT BETWEEN THE TEST SET I (FOR TOTAL CUSTOMERS) AND THE TEST SET II (FOR ONLY LONG-TERM LOYAL CUSTOMERS).

		Test set I			Test set II			
		RF	XGB	GBM	RF	XGB	GBM	
# of true positive users		63,778	63,249	61,932	212	213	201	
# of false positive users		3,917	4,307	4,713	568	615	586	
# of true negative users		22,233	21,843	21,437	1,558	1,511	1,540	
# of false negative users		10,072	10,601	11,918	62	61	73	
accuracy		0.8601	0.8509	0.8337	0.7375	0.7183	0.7254	
precision		0.9421	0.9362	0.9293	0.2718	0.2572	0.2554	
recall		0.8636	0.8565	0.8386	0.7737	0.7774	0.7336	
F1 score		0.9012	0.8946	0.8816	0.4023	0.3866	0.3789	
AUC		0.9358	0.9264	0.9067	0.8296	0.8129	0.8159	
expected profit	$\gamma:0.1$	C:0	704	503	488	5,192	5,169	4,908
		C:0.01	27	-173	-178	5,184	5,161	4,900
		C:0.1	-6,065	-6,253	-6,177	5,114	5,086	4,830
		C:1	-66,991	-67,053	-66,157	4,412	4,341	4,121
	$\gamma:0.05$	C:0	352	251	244	2,596	2,585	2,454
		C:0.01	-325	-424	-422	2,588	2,576	2,446
		C:0.1	-6,417	-6,504	-6,421	2,518	2,502	2,375
		C:1	-67,343	-67,305	-66,401	1,816	1,757	1,667
	$\gamma:0.01$	C:0	70	50	49	519	517	491
		C:0.01	-607	-625	-618	511	509	483
		C:0.1	-6,699	-6,705	-6,616	441	434	412
		C:1	-67,625	-67,506	-66,596	-261	-311	-296

[그림 3] 고객 전체레 이탈 예측 모델을 적용한 경우 (Test set I) 와 기대 이익이 큰 고객 집단만 선별하여 예측 모델을 적용한 경우 (Test set II) 에 대한 예측 성능과 기대 이익 비교 결과표

그렇다면, 아예 학습 단계에서 기대 이익을 최대로 하는 예측 모델을 만들도록 최적화 함수를 정의할 수는 없을 까요? 실제 이런 접근 방법을 제안한 논문이 있습니다. ‘Profit optimizing customer churn prediction with

Bayesian network classifiers (<https://content.iospress.com/articles/intelligent-data-analysis/ida00625>)' 는 바로 이렇게 기대 이익을 최대화 하는 분류기를 만드는 기법을 제안한 논문입니다.

정리하자면, 기계 학습 모델을 실전에 적용할 때는 모델 적용을 통해 기대되는 이익이 무엇인지를 명확히 정의 하고, 이렇게 정의된 기대 이익을 높이는 것을 목표로 한 예측 모델링 및 평가가 이뤄져야 합니다.

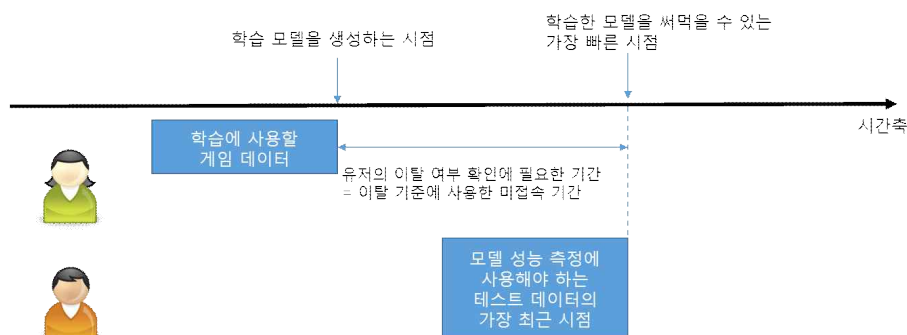
2. Concept drift 는 모델링 전반에 걸쳐 고려해야할 문제이다.

실전에서 예측 모델을 서비스에 적용해 본 분이라면 예측 모델이 처음에는 잘 맞다가 시간이 지날수록 점점 정확도가 떨어지면서 결국 유명무실해진 경험을 해본 적이 있을 것입니다. 이것을 'concept drift 문제' 라고 부릅니다. 'Concept drift' 는 기계 학습 분야에서 사용하는 용어로서 '시간이 지남에 따라 모델링 대상의 통계적 특성이 바뀌는 현상'을 의미합니다 (https://en.wikipedia.org/wiki/Concept_drift). 예측 모델은 모델링 대상의 통계적 특성 (패턴) 을 학습하는 것입니다. 만약 시간이 지나면서 예측 대상의 통계적 특성이 바뀐다면 예측 모델은 바뀌기 전의 특성만을 학습한 상태이기 때문에 쓸모가 없어지는 것이죠. 예측 모델링 대상에 따라 concept drift 가 그다지 문제가 되지 않는 경우도 있습니다. 가령, 이미지 인식 분야가 그렇습니다. 사진이나 영상에서 사람의 얼굴을 인식한다고 했을 때 사람의 얼굴이 가진 시각적인 특징은 시간이 지남에 따라 그리 바뀌지 않습니다(한 수 만년 쯤 지나면 바뀔 수 있겠죠). 아마 음성 인식이나 자연어 처리 분야 역시 그럴 것입니다. 반면, 제가 일하고 있는 게임 분야는 그렇지 않습니다. 게임 속 가상 세계 자체가 현실 세계보다 시간이 빨리 흐르기도 할 뿐더러 게임 캐릭터의 플레이 패턴은 게임을 진행하고 레벨이 오름에 따라 달라집니다. 게다가 게임 회사에서는 지속적인 게임 서비스 유지를 위해 게임 콘텐츠나 시스템을 정기적으로 업데이트하는데 그럴 때마다 플레이 특성이 바뀌기도 합니다.

따라서 실전에서 예측 모델을 사용할 때는 한번 만들어서 서비스에 적용하면 끝나는 것이 아니라 시간에 따라 예측 대상의 특성이 변하는 것을 모니터링하여 그 변화를 반영하거나 주기적으로 모델을 재학습하는 작업이 필요합니다. 'Learning under Concept Drift: an Overview' (<https://arxiv.org/abs/1010.4784>) 는 concept drift 를 고려한 학습 방법에 대해 잘 정리되어 있는 논문입니다 (혹은 위 논문보다 좀 더 짧은 <https://machinelearningmastery.com/gentle-introduction-concept-drift-machine-learning/> 를 읽어보시기 바랍니다).

그런데 사실 concept drift 문제는 단순히 모델의 유지 보수 문제가 아니라 학습 데이터의 라벨링부터 모델의 평가 방법에 이르기까지 전반에 걸쳐 고려해야할 문제입니다.

예를 들어, 고객의 통계적 특성이 매우 빠르게 바뀌는 (그래서 한달 전과 오늘의 고객 패턴이 매우 다른) 서비스가 있다고 가정해 보죠. 만약 이 서비스를 위한 이탈 예측 모델을 만들 때 '고객이 한달 이상 서비스를 이용하지 않는 경우'를 이탈로 정의한다면, 이 정의에 따라 라벨링된 학습 데이터로 학습한 예측 모델은 실전에서 전혀 쓸모가 없을 것입니다. 왜냐하면 이 모델을 학습하기 위해 만드는 학습 데이터는 모델을 실전에 적용하는 시점에서 최소 한 달 전 고객의 통계적 특성만 학습할 수 있기 때문입니다. 같은 이유로 인해 예측 모델을 평가할 때는 학습 데이터보다 최소한 한 달이 지난 데이터를 테스트 데이터로 사용해야 합니다. 그렇지 않고 학습 데이터와 같은 기간의 테스트 데이터로만 모델을 평가한다면 (평가 성능은 좋게 나오더라도) 실전에 적용했을 때 좋은 성능을 기대하기 어려울 것입니다. ([그림 4])



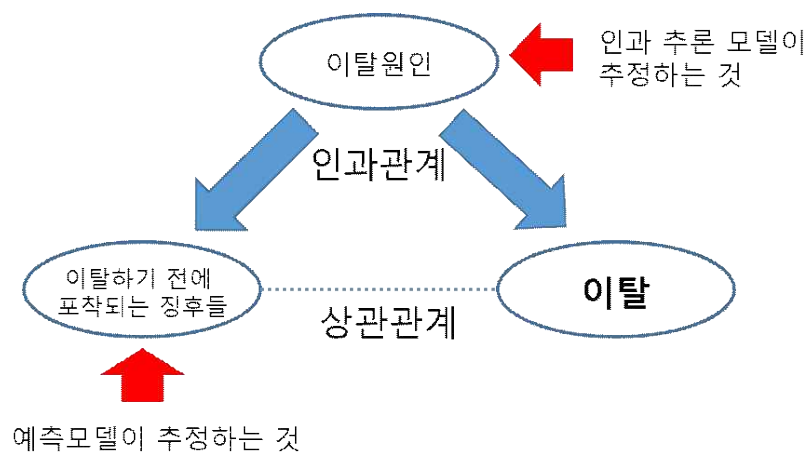
정리하자면, 실전에서 예측 모델을 만들 때는 예측 대상의 통계적 특성이 시간에 따라 변하는 정도를 먼저 확인하고 이에 따라 학습 데이터 라벨링이나 평가 방법을 설계해야 합니다.

3. 예측 모델링과 인과 추론 모델링은 (매우) 다르다.

제가 이탈 예측 모델을 서비스에 적용하기 위해 게임 개발 부서와 논의하면서 느낀 점은, 게임 개발 부서에서는 ‘누가 게임에서 이탈하느냐’가 아니라 ‘왜 고객이 이탈하느냐’를 알고 싶어 한다는 점이었습니다. 보통 기계 학습 분야에서 말하는 ‘예측 모델’은 전자에 대한 모델입니다. 반면 후자는 경제학이나 사회학에서 주로 다루는데 ‘인과 추론 모델’이라고 합니다.

‘예측 (prediction)’ 과 ‘인과 추론 (causal inference)’ 는 얼핏 비슷해 보이지만 매우 다른 기법입니다. 그리고 대개의 경우 예측보다 인과 추론이 훨씬 어렵습니다. 예를 들어, 옛날 사람들은 비가 왜 내리는지에 대한 인과 법칙을 알지 못했지만 밤에 달무리가 지는지, 제비가 땅에 낮게 나는지, 나이드신 어르신들이 허리나 무릎이 쭈시다고 하는지 등의 비가 오기 전에 많이 관찰되는 징후들을 보고 비를 예측할 수 있었습니다. 하지만 구름이 응결되고 비가 내리는 기상학적인 인과 법칙을 알게 된 것은 과학이 발달하고 나서의 일입니다.

이탈 예측 모델링 역시 마찬가지입니다. 우리는 실제 고객이 왜 이탈하는지 그 이유를 알지 못하더라도 이탈하기 전에 관측할 수 있는 현상들만 잘 포착하면 이탈 고객을 사전에 예측할 수 있습니다. 예를 들어, 게임에서 이탈하기로 마음 먹은 사람들은 대개 플레이 시간이 점점 줄어들거나 접속 주기가 불규칙해지고 본인이 보유한 아이템을 정리하는 등의 사전 징후를 보이는 경우가 많습니다. 일반적인 기계 학습 모델은 이런 사전 징후를 학습함으로써 이탈할 유저를 예측하게 됩니다. 하지만 이건 이탈의 원인이 아니라 이탈하기 전에 나타나는 현상일 뿐이죠. 예측 모델은 예측 변수와 응답 변수 사이에 상관성을 학습하는데 상관성이 꼭 인과성을 보장하는 것은 아니기 때문에 예측 모델이 이탈을 정확히 예측한다고 해서 인과 관계를 알 수는 없습니다. 이를 도식화하면 [그림 5]와 같습니다.



한편, 최근 많은 관심을 받고 있는 ‘설명 가능한 모델 (Explainable AI, XAI)’과 ‘인과 추론 모델’은 다릅니다. 마찬가지로 모델의 분류 기준을 해석하는 것도 인과 추론과 다릅니다. 즉, 이탈 예측 모델의 판정 기준을 해석하는 것이 이탈 원인을 파악하는 것은 아닙니다. 작년에 ‘게임 유저 이탈 예측’을 주제로 ‘빅콘테스트 (<http://www.bigcontest.or.kr/>)’ 라는 데이터 분석 경진 대회를 진행했는데 많은 참가팀이 이 둘을 혼동하는 경향이 있었습니다. 이를테면, Partial Dependence Plot (PDP) 등을 이용해서 본인들이 만든 예측 모델에서 어떤 변수들이 이탈율을 높이는지 파악한 후 이를 근거로 이탈 원인을 추정하였는데, PDP 등이 알려주는 것은 종속 변수인 ‘이탈’ 과 독립 변수인 이탈 전 징후 사이의 상관관계이지 인과 관계는 아닙니다. 이를 근거로 이탈 원인을 추정하면 논리적인 비약이 발생합니다. 제가 알기로 보통 사회/경제학에서는 인과 추론을 위해 구체적인 모델의 형태는 분석가가 가설을 토대로 직접 만들고, 관찰된 데이터를 이용한 통계 검정이나 회귀 분석을 통해 자신의 가설을 검증합니다. 그런데 엄밀하게 환경이 통제되는 과학 실험에 비해 관측 데이터는 통제할 수 없는

많은 잡음과 불확실성이 존재합니다. 통계학이나 경제학에서는 오래전부터 이런 통제 불가능한 요소로 인한 오차를 최대한 극복하기 위해 다양한 기법들을 개발했습니다. 이를 테면 독립 변수 간의 상관성 문제를 해결하기 위한 ‘도구 변수 (Instrumental Variable, IV) 법’이 대표적인 예입니다. 하지만 많은 똑똑한 학자들의 노력에도 불구하고 적절한 모델을 구성하는 것은 매우 어렵습니다. 그래서 최근 경제학에서는 이런 어려움을 해결하기 위해 기계 학습 분야에서 사용하는 다양한 자동화 기법을 도입하려는 움직임이 있습니다. Susan Athey의 ‘The Impact of Machine Learning on Economics (<https://www.nber.org/chapters/c14009.pdf>)’는 계량 경제학의 인과 추론 모델링 기법과 기계 학습 기법이 서로 융합할 경우 어떤 시너지와 새로운 가능성이 펼쳐질지에 대해 ‘매우 잘’ 정리한 논문입니다. 최근에 기계 학습 분야에서도 인과 추론에 대한 관심이 점차 깊어지고 있는데 이에 관심 있으신 분은 이 논문을 한번 읽어 보시기 바랍니다.

결국 데이터 분석을 할 때는 내가 지금 필요한 것이 ‘예측 모델’인지 아니면 ‘인과 추론 모델’인지에 대해 먼저 명확히 검토해야 합니다. 이 둘은 접근 방법도 다를 뿐더러 적용 방법이나 목표 역시 다릅니다. 이 글에서 계속 예로 드는 ‘이탈 분석’의 경우 예측 모델의 실행 부서는 대개 마케팅 부서가 될 것이고 이탈 예정 고객에 대한 프로모션 등을 통해 잔존 고객으로 전환하기 위한 목적으로 예측 모델을 활용하게 될 것입니다. 반면, 인과 추론 모델의 실행 부서는 게임 기획이나 개발 부서가 될 것이고 추론 결과는 게임 콘텐츠나 시스템을 개선하기 위한 목적으로 활용될 것입니다.

대개의 경우 예측보다 인과 추론이 더 어렵습니다. 따라서 가능하다면 예측 모델을 이용하는 방안을 먼저 검토하는 것이 좋습니다. 또한 A/B 테스트 등의 실험을 통해 예측 모델이 갖고 있는 한계를 실행 단계에서 극복하는 방법도 있습니다. 하지만 이런 방법이 항상 가능한 것은 아니기 때문에 목적이 인과 추론이라고 판단된다면 이에 맞는 방법을 사용해야겠습니다.

4. 마무리

지금까지 내용을 정리하자면 다음과 같습니다.

예측 모델링의 궁극적이 목표는 기대 이익을 최대화하는 것이다. 이를 위해선 예측 모델 적용에 의한 기대 이익과 비용을 고려하여 다음과 같은 조치가 필요하다.

1-1. 무조건 정확도를 높이기 보다는 높은 기대 이익이 예상되는 대상을 정확히 예측하기 위한 학습 데이터를 구축한다.

1-2. 예측 모델을 평가할 때 예측 정확도가 아니라 기대 이익을 계산할 수 있어야 한다.

1-3. 예측 모델 학습 시 가능하다면 오차를 이용하기 보다 기대 이익을 이용한 비용 함수를 정의한다.

concept drift 를 고려한 예측 모델링이 필요하다.

2-1. 모델링 하려는 데이터가 얼마나 concept drift 에 민감한지 먼저 파악해야 한다.

2-2. 예측 모델링 대상 및 라벨을 정할 때 concept drift 민감도를 고려해야 한다.

2-3. 학습 데이터 및 테스트 데이터 선정 시 시간에 따른 통계적 특성 변화를 고려해야 한다.

모델링의 목표가 ‘예측’인지 ‘인과 추론’인지에 따라 다른 접근 방법이 필요하다.

3-1. 예측은 상관 관계를 학습하는 것이다. 그런데 상관성이 있다고해서 인과관계가 성립하는 것은 아니다.

3-2. ‘모델의 해석’과 ‘인과 추론’은 다르다. 이 둘을 혼동하면 안된다.

3-3. 거의 모든 경우에서 ‘예측’보다 ‘인과 추론’이 더 어렵다. 따라서 가능하면 ‘예측’을 통해 할 수 있는 것들이 없는지 먼저 검토한다.

참고로 위 내용은 제가 성공한 경험을 토대로 정리한 것이 아니라 실패한 경험을 통해 깨달은 점을 정리한 것입니다. 때문에 위 내용이 정답이라고 확신할 수도 없을 뿐더러 위 고려 사항을 모두 만족해야 하는 것도 아닐 것입니다.

구글이 2015년에 발표한 ‘Hidden Technical Debt in Machine Learning Systems (<https://papers.nips.cc/paper/5656-hidden-technical-debt-in-machine-learning-systems.pdf>)’ 을 보면 머신 러닝 시스템을 구축할 때 실제 머신 러닝 모듈 자체의 비중은 매우 낮다고 합니다 (그림 6). 이와 비슷하게 실전에서 예측 모델을 만들 때는 보통 생각하는 기계 학습 모델링 기법이나 절차 외에도 고려해야 할 많은 요소들이 있습니다. 이 글에서는 ‘이탈’이라는 분야로 한정했으나 다른 예측 모델을 만들 때도 한번쯤 검토해봐야 할 주제들이라 생각합니다.